

# 搜索与作者匹配 全链路学习手册

从热榜候选、搜索增强到双通道路由与 LLM 重排

2

知乎只读 Tool

7

ready 作者画像

83 / 37

领域 / 视角原型

用途：项目梳理 · 方案评审 · 面试复盘

基于 CreatorOS main @ b4cab7a | 2026-08-26

已实现与目标方案严格分层，不把路线图表述为完成项

01 END-TO-END MAP

# 一页看懂：现在已经走到哪里

CreatorOS 的目标不是让一个 LLM 凭感觉包办全部工作，而是把稳定的数据获取、可解释的向量召回和需要语义判断的 LLM 重排组合成一条可恢复链路。当前已经完成两端连接器，中间的 Routing 正是下一阶段。



## 最关键的现状判断

已经能拿到热榜、搜索结果和作者画像，不等于已经完成作者匹配。当前缺口是：把热点拆成领域与视角文本，建立 CreatorOS 自己的画像检索索引，计算双通道得分，再让 LLM 对少量候选做最终判断。

## 两条路径不要混在一起

| 路径     | 什么时候运行                  | 输入                          | 输出               |
|--------|-------------------------|-----------------------------|------------------|
| 离线画像同步 | 作者新增或 corpus_version 变化 | PersonClone routing profile | CreatorOS 路由原型索引 |
| 在线热点路由 | 每日计划或用户发起               | 热榜 + 搜索增强 + 路由索引            | 每位作者的 Top-N 选题   |

02 DISCOVERY

# 热榜和搜索不是重复工作

| 能力 | 回答的问题                    | 当前对象                                  | 核心字段                                                            |
|----|--------------------------|---------------------------------------|-----------------------------------------------------------------|
| 热榜 | 现在什么受到关注?                | HotListSnapshot / HotTopic            | rank, title, url, summary, thumbnail_url                        |
| 搜索 | 这个热点到底发生了什么, 已经有哪些内容和观点? | ZhihuSearchSnapshot / ZhihuSearchItem | content_text, author, votes, comments, authority, ranking_score |

## 为什么选中热榜后还要搜索?

- 热榜只给候选和热度信号, 标题可能过短、含糊或缺少事件背景。
- 搜索补齐相关问题、回答、文章、作者、互动量与原文链接, 用来判断话题是否真实、是否已经饱和、有哪些冲突角度。
- 搜索发生在作者匹配之前。它服务于热点理解, 不负责直接挑作者。

示例: 热榜标题只有“某平台发布新规则”。搜索阶段会生成若干查询词, 找出规则原文、受影响人群、支持与反对观点; 随后热点拆解才形成“平台治理”领域文本和“效率与公平冲突”视角文本。

## 当前已实现

- get\_zhihu\_hot\_list(limit): 官方只读 GET, limit 为 1-30。
- search\_zhihu(query, count): 官方只读 GET, count 为 1-10。
- 结果先映射为内部不可变 dataclass, 再投影给 ToolResult; 密钥不进入消息、日志或仓库。

**边界提醒**

ContentText 可能很长, 且正文内链接不一定可靠。事实溯源优先使用搜索条目的顶层 url; 长结果由现有 ToolResult 投影控制上下文大小, 完整原文仍留在 Session。

03 HOTSPOT BRIEF

# 把热点拆成“写什么”和“怎么看”

下一步需要一个结构化 HotspotBrief。它不是最终文章，也不是作者选择结果，而是搜索资料到路由算法之间的稳定合同。

hotspot\_id: 稳定去重 ID  
title / source\_url: 事件标题与主来源  
hotspot\_domain\_text: 主题领域、对象、行业与关键实体  
hotspot\_perspective\_text: 可切入的价值冲突、问题意识与观察角度  
evidence\_refs: 支撑拆解的搜索条目 ID / URL  
freshness / risk\_flags: 时效性与事实、平台、品牌风险

## 为什么必须拆成两个文本？

| 文本               | 匹配对象                   | 解决的问题                | 错误理解          |
|------------------|------------------------|----------------------|---------------|
| domain_text      | domain prototypes      | 作者历史上是否覆盖过这个主题       | 写过某领域不等于拥有某人格 |
| perspective_text | perspective prototypes | 作者惯常的价值关注与推理方式是否适合切入 | 没写过该领域不等于不能跨域 |

## LLM 在这里做什么？

- 读取热榜标题与有限的搜索证据，输出受 Pydantic 约束的 HotspotBrief。
- 只做理解与归纳，不凭空补事实；每个关键结论必须能回指 evidence\_refs。
- 相同热点可缓存拆解结果，避免每位作者重复调用模型。

### 面试表达

我没有直接把热榜标题拿去和作者向量算相似度，因为短标题的信息密度太低。先用搜索证据构造结构化热点表示，再做路由，召回稳定性和可解释性都会更好。

04 PROFILE BOUNDARY

# PersonClone 提供画像，CreatorOS 负责路由

唯一正式入口是 GET /api/personas/{author}/routing-profile。CreatorOS 复用登录 Cookie，只消费 API 响应，不读取 PersonClone 本地 JSON、原始语料或 Qdrant。

| 画像类型                   | 表示什么      | 主要字段                                                        | 如何参与路由                      |
|------------------------|-----------|-------------------------------------------------------------|-----------------------------|
| domain_prototypes      | 作者过去写过什么  | label, description, retrieval_text, representative evidence | 匹配 hotspot_domain_text      |
| perspective_prototypes | 作者通常如何看问题 | values, trigger_cues, reasoning_pattern, boundaries         | 匹配 hotspot_perspective_text |

## 真实联调结果

| 作者                 | 领域 | 视角 | 状态    |
|--------------------|----|----|-------|
| 22-85-32-51        | 2  | 6  | ready |
| an-ling-91         | 3  | 3  | ready |
| ban-ma-ban-ma-30-2 | 17 | 5  | ready |
| lu-shi-han-89      | 12 | 6  | ready |
| mr-dang-77         | 5  | 5  | ready |
| superpeople-wudi   | 34 | 6  | ready |
| wu-ren-jun-28      | 10 | 6  | ready |

- 合计 83 个领域原型、37 个视角原型；统一声明 BAAI/bge-m3、1024 维。
- corpus\_version 是缓存失效键；版本变化后必须刷新该作者在 CreatorOS 的路由索引。
- ready 使用双通道；domain\_ready 只用领域；perspective\_pending 不得伪造视角；404 标记暂不可匹配。

### 为什么 get\_routing\_profile 不是 LLM Tool?

这份画像是路由服务的内部输入，体积大且结构稳定。由 Python 代码获取、校验、缓存和检索更可控；LLM 只看到 Top-K 候选的关键证据，而不是每轮吞下所有画像。

05 ROUTING INDEX

# 向量从哪里来：CreatorOS 自建路由索引

当前画像 API 返回可用于检索的文本和不透明 vector\_ref，但不返回原始 float 向量；CreatorOS 又被明确禁止直连 PersonClone 的 Qdrant。因此不能拿 point\_id 偷读底层存储。

| 方案                                                            | 优点                             | 代价                             | 判断   |
|---------------------------------------------------------------|--------------------------------|--------------------------------|------|
| CreatorOS 对 API 返回的 retrieval_text 重新 embedding，并写入自己的 Qdrant | 边界清晰、可批量检索、CreatorOS 自主控制召回与缓存 | 有一次重复向量计算，需要校验 embedding_model | 当前推荐 |
| PersonClone 新增正式 vector search API                            | 不重复 embedding，复用原向量库           | 路由召回依赖远端服务，接口和过滤能力需要扩展         | 未来可选 |

## 离线同步算法

- GET 作者画像，Pydantic 校验状态、模型、维度与 corpus\_version。
- 把每个 domain / perspective prototype 转为 RoutePrototypeDoc；保留 author\_id、prototype\_id、type、confidence 和 evidence IDs。
- 对 retrieval\_text 批量调用 BGE-M3，写入 CreatorOS 自有 collection；同一作者版本变化时原子替换旧版本。
- 索引里保存的是 PersonClone 正式 API 暴露的路由文本，不读取原始作者全文。

RoutingIndexKey = (author\_id, prototype\_id, prototype\_type, corpus\_version)  
Vector model = profile.embedding\_model  
Payload = label + confidence + representative evidence IDs + source version

### 模型一致性

只有热点向量与画像向量使用相同模型、维度和归一化方式，cosine similarity 才可比较。发现模型或维度不一致应拒绝路由并重建索引，而不是静默计算。

06 SCORING

# 双通道打分：先召回，再按作者聚合

对每个热点分别生成 domain vector 与 perspective vector，在两个 prototype\_type 子空间中检索。每个作者可能有很多原型，但只保留最匹配的领域原型和视角原型，避免平均向量稀释细分专长。

```
D(a,h) = max cosine(h_domain, domain_proto[a,i])
P(a,h) = max cosine(h_perspective, perspective_proto[a,j]) × confidence[a,j]
RouteScore(a,h) = w_domain × D(a,h) + w_perspective × P(a,h)
```

## 为什么用 Max Similarity?

- 作者可能覆盖金融、职场、关系等多个簇；把全部文章平均成一个向量会得到“什么都像一点、什么都不够像”的模糊中心。
- Max 会保留真正命中的细分原型，同时返回 winning prototype 作为可解释证据。
- 若担心偶然命中，可增加最低 confidence、最低文档数或 Top-2 一致性，而不是退回单一平均向量。

## M × N 到底贵不贵?

这里的 M × N 是向量相似度，不是 M × N 次 LLM 调用。120 个现有原型与几十个热点的计算量很小；规模扩大后用 Qdrant 做近似近邻检索即可。真正昂贵的语义判断只留给召回后的 Top-K。

| 产品模式        | 排序方向                                   | 适用场景           |
|-------------|----------------------------------------|----------------|
| 按作者日更（当前推荐） | 每位作者对所有热点打分 -> 保留 Top-K -> LLM 选 Top-N | 保证矩阵中每位作者按配置产出 |
| 按机会优先       | 每个热点对所有作者打分 -> 选择最适合作者                 | 不要求每位作者每天发文    |

### 同一热点能否给多个作者?

可以。CreatorOS 当前产品选择不设置“同一热点当天只能分配一次”的全局上限。不同作者可能从不同人格视角切入；只有业务出现内容同质化证据后，才增加组合多样性约束。

07 RERANKING

# 为什么 Top-K 后还要 LLM 重排

| 阶段           | 擅长什么                | 不擅长什么                  |
|--------------|---------------------|------------------------|
| Embedding 召回 | 便宜、稳定、批量处理语义相似度     | 难判断事实边界、表达空间、价值冲突和重复内容 |
| LLM 重排       | 结合证据比较切入角度、风险和作者独特性 | 全量调用成本高、延迟高、结果有随机性     |

## 重排输入应保持窄而有证据

- 一份 HotspotBrief，而不是所有搜索原文。
- 作者 Top-K 候选的分数、winning domain / perspective prototype、confidence。
- 每个 winning prototype 的少量 representative evidence，而不是完整历史语料。

```
RoutingDecision
- author_id / hotspot_id / selected
- final_rank / fit_reason / proposed_angle
- domain_evidence_ids / perspective_evidence_ids
- risk_flags / confidence / rejected_reasons
```

## 执行策略

- 每位作者先保留 embedding Top-K，再由 LLM 选出配置的 Top-N；Top-N 可以由 CLI 查询或作者配置改变。
- LLM 输出必须结构化，并引用候选证据 ID；无法说明依据的候选不进入生成阶段。
- 同一 HotspotBrief 只生成一次；同一作者的候选可以批量重排，降低固定 prompt 和缓存成本。

### 核心工程取舍

召回追求不漏，重排追求选准。把全量语义比较交给向量库，把少量复杂判断交给 LLM，是成本、延迟、可解释性之间的平衡。



08 WORKED EXAMPLE

# 用一个具体例子串起数据流

下面是目标流程示例，不代表当前已经自动执行。假设每天取 10 个热点，当前有 7 位作者、120 个路由原型。

| 步骤    | 输入                    | 动作                           | 输出规模                           |
|-------|-----------------------|------------------------------|--------------------------------|
| 1. 候选 | 知乎热榜                  | 取前 10 条并去重                   | 10 HotTopic                    |
| 2. 增强 | 每条标题                  | 搜索 5 条相关内容                   | 约 50 SearchItem                |
| 3. 拆解 | 热榜 + 搜索证据             | LLM 结构化 domain / perspective | 10 HotspotBrief                |
| 4. 召回 | 20 个热点向量 + 120 原型     | 双通道 cosine 检索与作者聚合           | 70 个 author-hotspot pair score |
| 5. 截断 | 每位作者 10 个 pair        | 保留 Top-K=5                   | 最多 35 候选                       |
| 6. 重排 | 候选 + winning evidence | LLM 为每位作者选 Top-N=1           | 7 RoutingDecision              |
| 7. 生成 | 选题与角度                 | 调用 PersonClone ask_author    | 7 份草稿                          |

## 一条候选为什么入选

热点：某平台推出新的内容治理规则

作者 A winning domain：平台经济与内容生态，D=0.81

作者 A winning perspective：先拆变量再判断，P=0.76 × confidence 0.88

LLM 重排：该作者虽然没写过这条具体规则，但有平台治理专长，且擅长区分规则目标、执行成本与副作用，因此提出“效率与公平如何权衡”的角度。

## 随后发生什么

- RoutingDecision 交给内容生成编排，不把画像当成最终答案模板。
- PersonClone 根据选定作者、问题与角度生成草稿；CreatorOS 负责后续 Judge、审批、发布和反馈。
- 生成失败不会推翻路由结果；两者是不同阶段，可分别重试与追踪。

09 CONTRACTS & RELIABILITY

对象、所有权与失败处理

| 对象                        | 所有者                          | 当前状态                  | 失败策略                     |
|---------------------------|------------------------------|-----------------------|--------------------------|
| HotTopic / SearchItem     | CreatorOS Discovery          | 已实现                   | 鉴权、超时、协议错误转稳定 ToolResult |
| HotspotBrief              | CreatorOS Discovery          | 待实现                   | 证据不足则拒绝拆解，不伪造事实          |
| AuthorRoutingProfile      | PersonClone 生成; CreatorOS 消费 | GET 已接通, Pydantic 待实现 | 404 或非 ready 时暂不可匹配      |
| RoutePrototypeDoc / Index | CreatorOS Routing            | 待实现                   | 按 corpus_version 原子刷新    |
| RoutingDecision           | CreatorOS Routing            | 待实现                   | 无证据或低置信候选不进入生成           |
| PersonaAnswer             | PersonClone 生成; CreatorOS 编排 | Client 已实现            | 生成错误与路由错误分开记录            |

哪些步骤适合 Tool，哪些适合普通代码？

- 热榜和搜索当前是只读 Tool：Agent 可以按任务动态决定调用与查询词。
- 画像同步、向量召回、分数聚合更适合确定性 Python 服务：可测试、可缓存、不会污染模型上下文。
- 热点拆解和候选重排使用 LLM，但输入输出由 Pydantic 合同约定。
- 发布属于高副作用能力，未来必须单独审批、幂等和审计，不能沿用普通只读 Tool 权限。

缓存最小设计

热榜按 snapshot 时间缓存；搜索按 query + 时间窗缓存；HotspotBrief 按 hotspot 内容哈希缓存；路由画像和向量索引按 author\_id + corpus\_version 缓存。缓存键跟业务版本走，而不是只设置一个盲目的 TTL。

最小可观测指标

- Discovery：调用成功率、热点去重率、搜索证据覆盖率。
- Routing：人工标注集 Recall@K / NDCG、LLM 接受率、跨域命中率、拒绝原因分布。
- Generation：草稿 Judge 通过率、人工改写率、发布成功率；效果反馈后再评估点击与互动。

## 10 INTERVIEW QA

# 面试高频追问：架构与算法

**Q1：为什么热榜之后还要搜索，不能直接匹配作者吗？**

热榜是趋势候选，不是充分语义表示。短标题缺少事件背景和冲突视角，直接 embedding 容易误召回。我用搜索补齐事实、相关内容和观点，再构造结构化 HotspotBrief，最后才进入作者路由。

**Q2：domain prototype 和 perspective prototype 有什么区别？**

domain 回答作者写过什么，来自历史标题聚类；perspective 回答作者通常如何思考，来自 Narrative Schema 的稳定视角。两者不一一对应，分开匹配才能支持“没写过该领域但人格视角适合”的跨域选题。

**Q3：为什么不用一个作者平均向量？**

多领域作者的平均向量会稀释细分专长。我保留多个领域和视角原型，对作者内部取 Max Similarity，并带回命中的 prototype 与 evidence，因此既保持召回能力又能解释为什么匹配。

**Q4：M × N 计算不会很贵吗？**

需要区分向量计算和 LLM 调用。M × N 的 cosine 计算在当前 120 个原型规模下极小，规模大后由 Qdrant 近邻检索解决；我不会做 M × N 次 LLM 判断，只把每位作者的 Top-K 交给 LLM 重排。

**Q5：为什么 embedding 之后还需要 LLM？**

Embedding 擅长语义相似，无法稳定判断事实边界、价值冲突、表达空间和品牌风险。LLM 只对少量召回候选结合证据重排，负责复杂但低吞吐的判断。

**Q6：为什么不让 LLM 直接读取所有画像并选择？**

全量画像会让上下文膨胀、成本和延迟随作者数增长，而且难以缓存和复现。确定性检索先缩小空间，LLM 看到 winning prototypes 与证据即可完成更可靠的比较。

## 11 INTERVIEW QA

# 面试高频追问：边界、可靠性与落地

**Q7: PersonClone 已经有 Qdrant, 为什么 CreatorOS 不直接连接?**

那会绕过服务边界, 把 CreatorOS 绑定到 PersonClone 的内部 collection、payload 和迁移细节。当前合同明确 vector\_ref 是不透明引用, 因此我只消费正式 API; 推荐在 CreatorOS 对公开的 routing text 建独立索引, 或者未来要求 PersonClone 提供正式 search API。

**Q8: 画像更新后怎么避免使用旧向量?**

每份画像携带 corpus\_version。CreatorOS 以 author\_id + corpus\_version 作为同步和缓存键, 版本变化时原子替换该作者的全部 prototype vectors; vector\_ref 也只在对应版本内有效。

**Q9: profile 不是 ready 怎么办?**

404 表示暂不可匹配; domain\_ready 只进入领域通道; perspective\_pending 不生成或猜测人格视角。路由分数会根据可用通道重新归一化, 并在决策中记录降级原因。

**Q10: 为什么画像读取不注册成 Agent Tool?**

Tool 适合让模型动态决定动作; 画像读取、缓存和检索是确定性的内部数据路径。把整份画像暴露给模型会浪费上下文并削弱边界, 所以由 Routing Service 消费, 只把 Top-K 证据提供给 LLM。

**Q11: 同一热点匹配多个作者会不会内容重复?**

当前业务允许多个作者命中同一热点, 因为他们可从不同视角切入。我不会先加没有需求证据的全局上限; 后续若同质化指标变差, 再在重排阶段增加角度去重或组合多样性约束。

**Q12: 如何证明路由真的有效?**

先构建热点-作者人工标注集, 离线看 Recall@K 和 NDCG; 上线观察 LLM 选择接受率、人工改写率和 Judge 通过率。发布数据稳定后, 再用互动指标做延迟反馈, 但不直接把流量等同于内容质量。

## 12 INTERVIEW PLAYBOOK

# 面试时怎样诚实又有亮点地讲

## 60 秒项目介绍

CreatorOS 是面向多创作者矩阵的自治运营 Agent。我把链路拆成趋势发现、热点理解、作者路由、数字分身生成、质量评审和发布反馈。当前已接通知乎官方热榜与搜索，也通过独立 FastAPI 服务读取 7 位作者的 120 个领域/视角原型。路由层采用领域与人格视角双通道：先用向量检索对作者内部多原型取 Max Similarity，再把带证据的 Top-K 候选交给 LLM 重排，从而避免全量 LLM 匹配，并支持跨领域但人格视角契合的选题。当前正在实现画像 Pydantic 合同和 CreatorOS 自有路由索引，后续再接生成评审与发布。

## 一定要区分完成项和设计项

| 可以说“已完成”                                              | 应说“已设计 / 正在实现”               |
|-------------------------------------------------------|------------------------------|
| 知乎官方热榜与搜索 Tool；真实 API 验证                              | HotspotBrief 自动拆解            |
| PersonClone 作者列表、SSE 生成接口、routing profile GET         | CreatorOS 路由向量索引与 Max 聚合     |
| 7 位作者画像真实读取：83 domain + 37 perspective                | Top-K + LLM 重排、Judge、发布和反馈闭环 |
| Agent Runtime、Streaming、Session、Compaction、ToolResult | 定时自治运营与生产级任务恢复               |

## 接下来三个最小切片

- 1. 用真实 wire shape 建 AuthorRoutingProfile Pydantic 模型，并实现状态降级。
- 2. 定义 RoutePrototypeDoc，同步 120 个原型到 CreatorOS 自有向量索引，按 corpus\_version 刷新。
- 3. 定义 HotspotBrief 与双通道 scorer，用一组真实热点完成 Top-K，再接 LLM 重排。

### 一句话记忆

热榜负责发现，搜索负责理解，画像负责描述作者，向量负责召回，LLM 负责少量复杂判断，PersonClone 负责按选定作者生成。

## 资料与校准基线

CreatorOS repository: <https://github.com/SlamWeb/CreatorOS>

基线 commit: b4cab7a

实现来源: creatoros/discovery, creatoros/integrations/zhihu.py, creatoros/integrations/personclone.py, SPEC.md

PersonClone API contract: 用户于 2026-08-26 提供；真实画像字段与 7 位作者状态已通过本地服务复验。